

Rapport Bonus — Second Mode d'Échec
Shortcut Learning / Corrélation Spurieuse
via la Variable Month

Students: SAAIDI Salma & EL BAHTOURI Aya

1. Research Question and Chosen Dataset

1.1 Contexte du rapport bonus

Le projet principal étudie le **mode d'échec par déséquilibre de classes** (class imbalance) sur le dataset UCI Online Shoppers Purchasing Intention. Les Notebooks 1 à 3 exposent ce mode d'échec, testent son hypothèse causale par une expérience contrôlée, et évaluent des corrections (SMOTE + AdaBoost, PSO + SMOTE + AdaBoost).

Ce rapport bonus investigate **un second mode d'échec indépendant** : le **shortcut learning** (raccourci d'apprentissage) via la variable catégorielle Month. Ce mode d'échec est distinct du premier : il ne concerne pas la proportion d'exemples positifs, mais la **nature de l'information exploitée** par les modèles pour prendre leurs décisions.

1.2 Présentation du dataset

Le dataset utilisé est le **UCI Online Shoppers Purchasing Intention Dataset** (ID : 468), contenant 12 330 sessions web décrites par 17 variables. La variable cible binaire Revenue indique si la session a abouti à un achat (True / 1, environ 15,5 %) ou non (False / 0, environ 84,5 %).

Parmi les 17 variables, Month est une variable catégorielle indiquant le mois de la session (Feb à Dec). Elle est encodée par OneHotEncoder dans le pipeline de prétraitement. C'est cette variable qui fait l'objet de l'investigation dans ce rapport.

Tableau 1 — Synthèse du cadre d'investigation bonus

Dataset	Tâche	Cible	Raccourci suspecté	Mode d'échec
Online Shoppers Purchasing Intention	Classification binaire	Revenue	Month (mois de la session)	Shortcut learning / corrélations spurieuses

1.3 Pourquoi Month est une variable suspecte

La variable Month peut légitimement encoder des informations comportementales : les promotions saisonnières, les fêtes de fin d'année, les comportements de vacances ou les campagnes marketing sont réellement liés au mois de l'année. Dans cette mesure, Month peut contenir un signal causal.

Cependant, Month peut aussi devenir un **raccourci statistique** : un modèle non linéaire suffisamment expressif peut apprendre la règle « Novembre ou Décembre → achat probable » à partir des corrélations dans les données d'entraînement. Cette règle est **statistiquement fondée dans le dataset actuel** — les mois de fin d'année ont effectivement des taux d'achat plus élevés (voir Figure 1). Cependant, elle est potentiellement **fragile** : si les données de test proviennent de mois non vus, ou si la stratégie commerciale change d'une année sur l'autre, cette règle ne généralise plus.

C'est précisément ce que la littérature appelle un *shortcut learning* : le modèle exploite une corrélation accessible dans les données d'entraînement, même si celle-ci n'est pas causalement stable. Par analogie avec le cas canonique du classifieur husky-vs-loup qui apprend à détecter la neige en arrière-plan plutôt que l'animal, un modèle exploitant Month comme raccourci peut fonctionner bien en distribution mais échouer sous un changement de contexte temporel.

1.4 Question de recherche

Les classificateurs non linéaires entraînés sur le dataset Online Shoppers exploitent-ils la variable Month comme un raccourci saisonnier, de sorte qu'ils obtiennent de bonnes performances en distribution mais deviennent moins robustes lorsqu'ils sont évalués sur des mois non vus pendant l'entraînement ? La suppression de Month améliore-t-elle la robustesse hors distribution ?

Caractère falsifiable de la question

Cette question est formulée de manière falsifiable : elle spécifie à l'avance des résultats expérimentaux qui l'affaibliraient ou la réfuteraient.

L'hypothèse serait affaiblie ou réfutée si :

- Month n'apparaît pas parmi les variables importantes (importance par impureté ou permutation importance) pour aucun des trois modèles ;
- la permutation aléatoire de Month dans le set de test ne cause aucune chute de performance — indiquant que les modèles ne reposent pas sur cette variable ;
- les modèles entraînés AVEC Month ne se dégradent pas davantage que les modèles SANS Month sur l'évaluation hors distribution (mois de Nov/Déc) ;
- les modèles SANS Month ne sont pas plus robustes ou plus stables sur les mois non vus.

En revanche, si plusieurs de ces conditions sont violées — Month est importante, la permutation la dégrade, et les modèles SANS Month sont plus stables en OOD — l'hypothèse est soutenue.

2. Modèles de Référence et Symptôme Observé

2.1 Clarification du cadre d'analyse

Ce rapport bonus ne cherche pas à reprendre le problème de déséquilibre de classes, qui est l'objet du projet principal. L'objectif ici est d'observer un **symptôme différent** : la dépendance potentielle des modèles à une variable temporelle — Month — dont le rôle causal n'est pas garanti au-delà du contexte d'entraînement.

Cela implique un protocole d'évaluation différent. L'outil principal n'est plus la confusion matrix entre classes majoritaire et minoritaire, mais la **comparaison systématique** entre des modèles entraînés AVEC et SANS Month, d'abord en split aléatoire classique, puis en évaluation hors distribution (OOD) sur les mois de Novembre et Décembre.

2.2 Modèles testés

Trois familles de modèles non linéaires sont utilisées, chacune testée dans deux conditions :

- **WITH Month** : la variable Month est incluse dans le feature set et encodée via OneHotEncoder.

- **WITHOUT Month** : la variable Month est exclue du feature set avant toute transformation.

Cela produit six modèles distincts :

- Random Forest WITH Month / WITHOUT Month
- LightGBM WITH Month / WITHOUT Month
- MLP (Multilayer Perceptron) WITH Month / WITHOUT Month

Les hyperparamètres sont identiques pour les versions WITH et WITHOUT Month de chaque famille, afin d'isoler l'effet de la présence de Month. Aucun modèle linéaire n'est utilisé.

2.3 Métriques d'évaluation

Les métriques utilisées sont celles du projet principal, centrées sur la classe positive Revenue = True qui reste la classe minoritaire (~15,5 %) :

- **Accuracy** : performance globale, insuffisante seule en contexte de déséquilibre.
- **Precision_true** : fraction des prédictions positives qui sont correctes.
- **Recall_true** : fraction des vrais acheteurs correctement identifiés — métrique critique.
- **F1_true** : moyenne harmonique précision/recall pour la classe positive.
- **ROC-AUC** : aire sous la courbe ROC — mesure la capacité de discrimination globale.
- **PR-AUC** : aire sous la courbe Précision-Rappel — plus informative que ROC-AUC en contexte de déséquilibre.

Même pour ce bonus centré sur Month, PR-AUC et Recall_true restent les métriques prioritaires car Revenue=True est une classe minoritaire. Un modèle plus robuste hors distribution ne devrait pas masquer sa robustesse derrière une accuracy plus élevée

2.4 Symptômes observés

L'investigation du shortcut learning via Month s'appuie sur quatre catégories de symptômes :

Symptôme 1 — Variabilité du taux d'achat selon les mois

L'EDA révèle que le taux d'achat varie significativement selon les mois. Les mois de Novembre et Décembre présentent historiquement des taux d'achat plus élevés que les mois estivaux, liés aux fêtes de fin d'année. Cette variabilité crée une corrélation statistique exploitable entre Month et Revenue, indépendamment du comportement de navigation individuel.

Symptôme 2 — Présence de Month dans les importances de variables

Pour les modèles d'arbres (Random Forest, LightGBM) entraînés AVEC Month, les variables encodées depuis Month (après OneHotEncoding) peuvent apparaître parmi les 15 variables les plus importantes. Ce symptôme est recherché à travers deux mesures complémentaires :

- **Importance par impureté (MDI)** : calculée directement depuis les arbres de décision. Biaisée mais informative.
- **Permutation importance** : mesure la chute de PR-AUC lorsque Month est permutée aléatoirement. Plus robuste et directement interprétable.

Symptôme 3 — Divergence entre évaluation aléatoire et évaluation OOD

L'Expérience A compare les performances WITH et WITHOUT Month en split aléatoire stratifié (60/20/20). Ce split mélange tous les mois dans train et validation. Si Month apporte un gain uniquement en distribution, cela suggère une possible dépendance saisonnière.

L'Expérience B, détaillée en Section 3, constitue le test contrôlé principal en examinant le comportement OOD.

Symptôme 4 — Dépendance mesurée par permutation de Month

Le test de permutation mesure directement la dépendance effective du modèle à Month : si permuter aléatoirement les valeurs de Month dans le set OOD cause une chute significative de PR-AUC ou de Recall_true, cela constitue une preuve directe que le modèle exploite cette variable dans ses décisions.

3. Hypothèse Causale et Expérience Contrôlée

3.1 Formulation de l'hypothèse causale

La variable Month encode une corrélation saisonnière entre le mois de visite et la probabilité d'achat. Les modèles non linéaires — Random Forest, LightGBM et MLP — peuvent exploiter cette corrélation comme un raccourci d'apprentissage. Si cette hypothèse est correcte, les features dérivées de Month devraient apparaître comme prédicteurs importants, les performances devraient varier entre une évaluation in-distribution et une évaluation hors distribution, et les modèles entraînés AVEC Month devraient être moins robustes sur des mois non vus que les modèles entraînés SANS Month.

Mécanisme causal postulé : le modèle observe que certains mois (par exemple Novembre, Décembre) sont associés à des taux d'achat élevés dans les données d'entraînement. Il encode cette régularité sous forme de règles de décision. Ces règles sont correctes en distribution, mais elles ne reposent pas sur le comportement de navigation individuel de l'utilisateur — elles reposent sur la saisonnalité agrégée. Si le modèle est ensuite exposé à des sessions issues d'un autre contexte temporel (autre mois, autre année), ces règles peuvent ne plus s'appliquer.

3.2 Protocole expérimental — Trois tests contrôlés

Test 1 — Expérience A : Split Aléatoire WITH vs WITHOUT Month

Protocole : split aléatoire stratifié identique (60/20/20), hyperparamètres identiques, prétraitement identique. La seule variable qui change entre les six modèles est la présence ou l'absence de Month.

Ce test mesure : si Month apporte un gain de performance *en distribution*. Si les performances WITH et WITHOUT Month sont similaires, cela indique que Month n'est pas indispensable et que les autres features (PageValues, ExitRates, VisitorType, etc.) capturent l'essentiel du signal prédictif.

Limite de ce test : un split aléatoire mélange tous les mois dans les données d'entraînement et de validation. Il ne peut pas détecter une fragilité due à une distribution temporelle différente.

Test 2 — Expérience B : Split OOD par Mois (Test Principal)

Protocole : les modèles sont entraînés uniquement sur les sessions des mois Feb, Mar, May, Jun, Jul, Aug, Sep, Oct. Le set de test OOD contient exclusivement les sessions de Novembre et Décembre — des mois associés à des taux d'achat plus élevés que la moyenne. Une validation interne (20% des données d'entraînement) est utilisée pour la sélection de modèle. Le set OOD n'est pas utilisé pour la sélection — il est réservé à l'évaluation finale.

Ce test est le test contrôlé principal : il simule un changement de distribution temporelle. Si les modèles WITH Month se dégradent davantage que les modèles WITHOUT Month sur Nov/Dec, cela soutient l'hypothèse que Month a été exploitée comme raccourci fragile.

Contrôle rigoureux : les mois d'entraînement sont identiques pour WITH et WITHOUT Month. La différence de performance est donc imputable à la seule présence ou absence de Month dans le feature set.

Test 3 — Test de Permutation de Month

Protocole : pour chaque modèle AVEC Month (RF, LightGBM, MLP), les valeurs de Month dans le set OOD (Nov/Dec) sont permutées aléatoirement, tout en laissant les autres variables intactes. La performance est mesurée avant et après permutation.

Interprétation : ce test isole l'effet de Month en perturbant uniquement cette variable. Une chute significative de PR-AUC ou de Recall_true après permutation constitue une preuve directe et robuste que le modèle repose sur Month pour ses prédictions.

Avantage par rapport aux importances de variables : l'importance par impureté peut surestimer l'importance de variables corrélées ou à haute cardinalité. Le test de permutation fournit une mesure plus directe de la dépendance fonctionnelle du modèle à Month.

3.3 Critères d'interprétation — Sans forcer la conclusion

L'interprétation des résultats doit rester fidèle aux données. Trois scénarios sont possibles :

- **Hypothèse soutenue :** les modèles WITH Month présentent une chute de PR-AUC plus prononcée que les modèles WITHOUT Month sur l'évaluation OOD ; la permutation de Month dégrade les performances de façon substantielle ($\Delta \text{PR-AUC} < -0,05$ au minimum) ; et Month figure parmi les variables importantes pour au moins deux des trois familles de modèles.
- **Hypothèse partiellement soutenue :** certains modèles (par exemple Random Forest ou LightGBM) montrent les symptômes attendus, mais d'autres (par exemple MLP) ne montrent qu'une faible dépendance à Month. Dans ce cas, la sensibilité au raccourci dépend de l'architecture du modèle.
- **Hypothèse non soutenue :** les modèles WITHOUT Month ne sont pas plus robustes en OOD, la permutation de Month ne cause pas de dégradation significative, et Month n'apparaît pas parmi les variables importantes. Cela suggérerait que Month contient principalement un signal saisonnier légitime, non fragile, ou que d'autres variables encodent déjà l'information temporelle (ex. SpecialDay, TrafficType).

4. Correction Proposée et Évaluation

4.1 Correction : suppression de Month

La correction proposée est la **suppression de la variable Month** du feature set. Les modèles SANS Month sont entraînés uniquement sur des variables comportementales : PageValues, ProductRelated, ProductRelated_Duration, BounceRates, ExitRates, VisitorType, Weekend, et les features administratives et informationnelles.

4.2 Pourquoi cette correction cible la cause, et non le symptôme

Une correction symptomatique consisterait à ajuster le seuil de décision ou à régler des hyperparamètres pour améliorer les métriques sur le set OOD. Une **correction causale** consiste à retirer la source suspectée du raccourci — c'est ce que fait la suppression de Month.

En forçant les modèles à apprendre exclusivement à partir de signaux comportementaux, on réduit la probabilité que les décisions reposent sur la saisonnalité agrégée plutôt que sur le comportement individuel de navigation. Si l'hypothèse est correcte, cette correction doit améliorer ou stabiliser les performances sur des mois non vus.

Cette correction a un coût potentiel : si Month contient effectivement un signal causal légitime (les comportements d'achat de novembre sont réellement différents), sa suppression peut réduire les performances globales. Ce trade-off doit être évalué explicitement.

4.3 Évaluation de la correction

La comparaison finale entre modèles WITH et WITHOUT Month est effectuée sur le **set OOD Nov/Dec**. L'objectif est de mesurer si la suppression de Month réduit l'écart de robustesse entre évaluation in-distribution et évaluation hors distribution.

4.4 Critères d'évaluation de la correction

Les résultats de la correction doivent être interprétés selon les critères suivants :

- **Si WITHOUT Month améliore PR-AUC ou Recall en OOD** : la correction est efficace. Le retrait de Month a réduit la dépendance au raccourci saisonnier et forcé le modèle à apprendre des signaux plus robustes.
- **Si WITHOUT Month produit des performances similaires en OOD** : la correction est neutre. Month n'était pas la principale source d'instabilité. La robustesse OOD est déterminée par d'autres facteurs (shift de distribution de la cible, bruit dans les features comportementales, etc.).
- **Si WITHOUT Month dégrade les performances en OOD** : la correction est contre-productive. Month contenait un signal saisonnier légitime — son retrait appauvissait le modèle. Dans ce cas, l'hypothèse de shortcut learning est affaiblie.
- **Si les résultats sont hétérogènes selon les familles de modèles** : la sensibilité au raccourci dépend de l'architecture. Les modèles d'arbres (Random Forest, LightGBM) peuvent être plus susceptibles d'exploiter Month comme raccourci que MLP, en raison de leur tendance à effectuer des splits nets sur des variables catégorielles.

5. Menaces à la Validité

Cette section adopte une posture *auto-critique* conformément aux exigences du PDF du mini-projet. Reconnaître explicitement les limites d'une analyse renforce sa crédibilité scientifique.

5.1 Saisonnalité réelle vs raccourci

Month n'est pas nécessairement une variable spurieuse. En e-commerce, la saisonnalité influence réellement les décisions d'achat : les promotions de Black Friday et de Noël, les comportements de vacances, les campagnes de rentrée scolaire ont un impact causal sur la propension à acheter. Si ces effets sont réels et reproductibles d'une année sur l'autre, Month est une variable légitime.

La distinction entre un *signal causal stable* et un *raccourci fragile* ne peut pas être tranchée par les données d'une seule année. Cette limite est fondamentale : même si la correction (retrait de Month) améliore la robustesse OOD dans ce dataset, elle pourrait dégrader les performances sur un autre dataset où la saisonnalité est plus stable et réellement prédictive.

5.2 Shortcut learning vs shift de distribution de la cible

Le split OOD utilise Nov/Dec comme set de test. Ces mois ont un taux d'achat plus élevé que les mois d'entraînement (~15-20 % vs ~12-14 %). Cette différence de distribution de la variable cible constitue un **changement de distribution indépendant du shortcut**. Une chute de performance en OOD peut donc s'expliquer en partie par ce shift de la variable Revenue, et non uniquement par une fragilité liée à Month.

Pour séparer ces deux effets, il faudrait comparer des mois OOD avec des taux d'achat proches des mois d'entraînement, et tester séparément l'effet de Month — ce qui n'est pas faisable sans un dataset plus complet couvrant plusieurs années.

5.3 Catégories inconnues pour OneHotEncoder

Le pipeline utilise `OneHotEncoder(handle_unknown='ignore')`. Si Nov/Dec ne sont pas vus pendant le fit du préprocesseur (entraîné sur Feb–Oct), les colonnes correspondant à ces mois sont encodées comme vecteurs nuls. Le modèle WITH Month ne dispose donc d'aucune information sur le mois pour les sessions OOD — il se comporte comme s'il ne savait pas que c'est Novembre ou Décembre.

Cela rend le test OOD plus équitable pour WITH Month (puisque Month n'apporte aucune information de Novembre ou Décembre), mais complique l'interprétation : la comparaison WITH vs WITHOUT Month en OOD n'est plus purement « avec versus sans Month » — c'est « avec Month encodée comme inconnue versus sans Month du tout ».

Si Nov et Dec sont présents dans `X_train` (car le split est OOD et non chronologique pour l'inner split), ce point peut être moins critique. Vérifier les mois représentés dans le training set de l'Expérience B.

5.4 Taille réduite du set OOD et instabilité des métriques

Le set OOD Nov/Dec représente environ 20-25 % du dataset. Sur ce sous-ensemble, le nombre de sessions avec `Revenue = True` est limité. Les métriques `Recall_true`, `F1_true` et PR-AUC estimées sur peu d'exemples positifs ont une variance élevée. Une différence de 0,02 sur le PR-AUC entre WITH et WITHOUT Month peut ne pas être statistiquement significative.

Des intervalles de confiance par bootstrap ou une répétition de l'expérience avec plusieurs seeds seraient nécessaires pour des conclusions robustes.

5.5 Graine aléatoire unique

Toutes les expériences utilisent `random_state = 42`. Cela garantit la reproductibilité exacte, mais une seule graine ne permet pas d'évaluer la variance des conclusions. Le comportement de chaque modèle — notamment MLP, sensible à l'initialisation des poids — peut varier selon la graine. Une analyse sur 10 ou 20 graines avec rapport de moyenne $\pm$ écart-type renforcerait considérablement la solidité des conclusions.

5.6 Biais de l'importance par impureté

L'importance par impureté (MDI) des forêts aléatoires est connue pour **surestimer l'importance des variables à haute cardinalité** ou des variables continues. Month encodée par OneHotEncoder génère 11 colonnes binaires (une par mois représenté). Ces colonnes multiples peuvent collectivement recevoir une importance élevée même si chaque colonne individuellement est peu prédictive. La permutation importance, qui mesure la chute de performance globale, est plus appropriée mais elle aussi instable sous des features corrélées.

5.7 Sensibilité du MLP aux choix d'architecture

Les résultats du MLP dépendent de l'architecture (`hidden_layer_sizes`), du taux d'apprentissage, de l'early stopping, de l'initialisation des poids et du scaling des entrées. Une architecture différente pourrait présenter une dépendance à Month très différente. Les conclusions pour MLP doivent être interprétées avec la précision supplémentaire que les choix d'hyperparamètres peuvent masquer ou amplifier l'effet Month.

5.8 Généralisation limitée au-delà du dataset

Les résultats de ce rapport concernent ce dataset précis, collecté sur un seul site e-commerce dans un contexte et une période donnés. D'autres sites web, d'autres marchés géographiques, d'autres années ou d'autres stratégies marketing pourraient donner un rôle fondamentalement différent à Month.

5.9 Réutilisation du set OOD pour plusieurs analyses

Le set OOD Nov/Dec est utilisé dans plusieurs analyses successives : comparaison WITH/WITHOUT Month, test de permutation, et matrices de confusion. Une utilisation aussi intensive d'un même set de test constitue un risque de *test leakage implicite* : si les conclusions d'une analyse guidaient les décisions de modélisation, les résultats finals seraient biaisés. Dans le cadre de ce rapport, les modèles ne sont pas sélectionnés sur la base des résultats OOD — la sélection se fait sur la validation interne — ce qui limite ce risque, mais ne l'élimine pas totalement.

5.10 Confounding avec d'autres variables

Des variables comme `SpecialDay`, `TrafficType`, ou `VisitorType` peuvent être corrélées avec Month. Par exemple, `SpecialDay` encode la proximité avec des jours fériés — information partiellement redondante avec les mois de fin d'année. La suppression de Month ne garantit pas l'élimination de toute l'information temporelle : ces variables proxy peuvent conserver une partie du signal saisonnier.

6. Conclusion et Ce que Ce Bonus Nous a Appris

6.1 Synthèse des investigations

Ce rapport bonus a investigué un **second mode d'échec** sur le dataset Online Shoppers Purchasing Intention, indépendant du déséquilibre de classes : le **shortcut learning via la variable Month**. L'investigation a suivi la structure scientifique en quatre étapes requise par le mini-projet : question de recherche, symptôme observé, hypothèse causale et test contrôlé, correction et évaluation.

Trois familles de modèles non linéaires ont été utilisées (Random Forest, LightGBM, MLP) dans deux conditions (WITH Month / WITHOUT Month). Trois expériences contrôlées ont été conduites :

- **Expérience A** (split aléatoire) : vérification si Month apporte un gain in-distribution.
- **Expérience B** (split OOD par mois) : vérification si les modèles WITH Month se dégradent davantage sur Nov/Dec.
- **Test de permutation** : vérification directe de la dépendance fonctionnelle du modèle à Month.

6.2 Ce que l'analyse révèle

L'EDA montre une **variabilité saisonnière réelle** du taux d'achat selon les mois — ce qui crée une corrélation statistiquement exploitable par les modèles. Les importances de variables permettent de vérifier si Month est effectivement utilisée comme prédicteur important. Le split OOD est l'outil analytique le plus informatif : il simule un changement de distribution temporelle et révèle si la dépendance à Month se traduit par une fragilité réelle.

Le résultat de ce rapport dépend des métriques numériques réelles issues du notebook. Si les résultats montrent que les modèles WITHOUT Month sont plus robustes ou plus stables en OOD, l'hypothèse est **partiellement ou pleinement soutenue**. Si les résultats sont mitigés ou contradictoires selon les familles de modèles, la conclusion est que la sensibilité au shortcut **dépend de l'architecture**.

6.3 Conclusion de portée générale

Cette étude bonus montre qu'un modèle peut échouer non seulement à cause d'un déséquilibre de classes, mais aussi parce qu'il exploite une corrélation facile et potentiellement instable. L'analyse de Month révèle l'importance d'évaluer les modèles hors distribution et de ne pas se limiter aux performances obtenues sur un split aléatoire. Même lorsque la correction par suppression de Month n'améliore pas uniformément tous les modèles, elle permet de tester explicitement si la performance repose sur une information temporelle fragile. La leçon principale est qu'un bon score en validation classique ne prouve pas que le modèle a appris un comportement robuste.

6.4 Ce que ce bonus enseigne sur l'approche scientifique

1. **Deux modes d'échec peuvent coexister** : le déséquilibre de classes (projet principal) et le shortcut learning (bonus) sont des pathologies indépendantes. Un modèle qui échoue sur l'une peut aussi échouer sur l'autre, mais pour des raisons différentes.

2. **L'évaluation hors distribution est indispensable** : un split aléatoire ne peut pas révéler la fragilité d'un modèle face à un changement de contexte temporel. L'Expérience B (split OOD) est le test diagnostique le plus puissant.
3. **La correction causale vs symptomatique** : retirer Month cible directement la source suspectée du raccourci. Ajuster un seuil de décision ou régler des hyperparamètres auraient masqué le symptôme sans traiter la cause.
4. **L'interprétation ne doit pas forcer la conclusion** : si les données ne soutiennent pas l'hypothèse de shortcut learning, il faut l'admettre. Month peut contenir un signal saisonnier légitime — cette ambiguïté est inhérente à l'analyse de données réelles.
5. **Les menaces à la validité enrichissent l'analyse** : reconnaître que la chute OOD peut venir d'un shift de distribution de la cible (et pas seulement du raccourci), ou que les catégories de mois inconnues modifient le comportement de l'encodeur, rend les conclusions plus crédibles et plus utiles.

En synthèse : ce rapport bonus illustre que le diagnostic de l'échec d'un modèle nécessite une posture de chercheur, pas uniquement d'ingénieur. Formuler une hypothèse falsifiable, construire un test qui pourrait la réfuter, proposer une correction causale, et reconnaître honnêtement les limites de l'analyse.

